

제 6 장 범주형자료에 대한 추론 (개정판) 범주형자료에 대한 추론 (개정판)

범주형자료에 대한 추론

2026년 5월

Contents

제 6 장: 범주형자료에 대한 추론 (개정판)	2
6.0 범주형자료추론의 길잡이	2
6.0.1 6 장에서 다루는 네 가지 시나리오	2
6.0.2 가설검정 4 단계 (PCCC 체크리스트)	5
6.0.3 5 장 핵심개념의 6 장 연결	6
6.0.4 신뢰구간과 가설검정에서 SE 가 달라지는 이유	7
6.0.5 카이제곱분포의 직관 (§ 6.3 이전 필독)	8
6.0.6 본장의 학습 순서	12
6.1.2 비율에 대한 신뢰구간	19
6.1.3 비율에 대한 가설검정	21
6.1.4 조건이 충족되지 않을 때	23
6.1.5 비율을 추정할 때 표본 크기 결정	24
6.2 두 비율의 차이	26
6.2.1 두 비율 차이의 표본 추출 분포	27
6.2.2 두 비율 차이의 신뢰구간 (비합동 SE)	27
6.2.3 두 비율 차이의 가설검정 (합동 SE)	29
6.3 카이제곱 적합도 검정	31
6.3.1 적합도 검정의 동기: 배심원 인종 구성	31
6.3.2 카이제곱 검정 통계량	31
6.3.3 적합도 검정의 조건	31
6.3.4 사례 연구: S&P500 일별 등락의 독립성	32
6.4 이원분할표에서의 독립성 검정	33
6.4.1 기대빈도 계산	34
6.4.2 사례 연구: iPod 결함 공개 실험	34
6.4.3 검정 통계량과 자유도	34
6.5 장 요약	36
6.5.1 6 장 핵심개념 정리	36
6.5.2 5 장과 6 장의 연결	37
6.5.3 다음 장 예고	37

제 6 장: 범주형자료에대한추론 (개정판)

개정판안내

본개정판은 5 장에서도입한 **가설검정의기본개념** (p -값, 유의수준, 신뢰수준, 단측·양측검정, 제 1 종·제 2 종오류, 검정력)을 6 장의모든절에일관되게연결하기위해새절 **§ 6.0 범주형자료추론의길잡이**를추가하였다. 또한카이제곱분포에대한직관적설명을 § 6.3 이전에충분히다루어, 독자가“왜카이제곱인가”를이해한상태에서문제풀이로들어갈수있도록구성하였다.

5 장의핵심개념을충분히숙지한뒤이장을읽기를권한다. § 5.0 의가설검정 4 단계 (준비-확인-계산-결론), p -값과 α 비교 규칙, “기각못함과채택의차이”등은이장전체에서반복사용된다.

본장에서는 5 장에서배운추론의틀을범주형자료의다양한상황에적용한다. 먼저단일비율추론을복습하고, 두비율의차이로확장한뒤, 이장 후반부에서는 **카이제곱분포** (chi-square distribution) 에기반한새로운검정도구로분할표를다룬다. 분포는달라지지만가설검정의 큰흐름은 5 장에서배운것과동일하다.

6.0 범주형자료추론의길잡이

본절은 6 장전체에서다루는네가지검정시나리오를한눈에정리하고, 5 장의개념이어떻게 6 장에연결되는지를명시한다. 처음통계를배우는 독자는이절을충분히읽고 § 6.1 로넘어가는것이학습에도움이된다.

6.0.1 6 장에서다루는네가지시나리오

범주형자료에대한추론은자료의구조와묻는질문에따라네가지유형으로나뉜다.

시나리오	자료구조	핵심질문	검정방법	절
(a) 단일비율	1 개그룹의성공/실패	모집단비율 p 가특정값과같은가?	1-비율 Z-검정	§ 6.1
(b) 두비율의차이	2 개그룹의성공/실패	두모집단비율 p_1 , p_2 가같은가?	2-비율 Z-검정	§ 6.2
(c) 적합도검정	한변수의 k 개범주빈도	관측빈도가가정된분포와일치하는가?	카이제곱적합도	§ 6.3
(d) 독립성검정	두범주형변수의분할표	두변수가독립인가?	카이제곱독립성	§ 6.4

이네시나리오들은모두 5 장에서배운 **가설검정 4 단계절차**를공통으로따른다. 도구 (분포) 가정규분포에서카이제곱분포로바뀔뿐, 사고의흐름은완전히동일하다.

새로운시각: “어떤검정을쓸지”결정나무 학생들이 6 장에서가장자주막히는지점은“주어진문제에서어떤검정을써야하는가”이다. 다음 결정나무는문제해결의첫출발점이다.


판단순서: 1. 비교하려는그룹/범주의 **개수**를센다. 2. 1 개라면 § 6.1, 2 개라면 § 6.2 또는 2×2 카이제곱, 3 개이상이면카이제곱검정으로간다. 3. 변수가 **두개**이고그관계를묻고있다면 § 6.4 독립성검정이다. 4. 한변수의빈도가가정된분포 (균등, 기하, 멘델의유전법칙등) 와맞는지묻는다면 § 6.3 적합도검정이다.

제6장 개요: 범주형 자료에 대한 4가지 추론 시나리오



Figure 1: 그림 6.0.1: 6 장에서 다루는 네 가지 추론 시나리오

제6장 결정나무: 범주형 자료에서 어떤 검정을 쓸 것인가?




※ 조건이 위배되면: 시뮬레이션, 클로퍼-피어슨 구간, 피셔 정확검정 등 대안 사용

Figure 2: 그림 6.0.6: 어떤검정을쓸것인가 - 결정나무

6.0.2 가설검정 4 단계 (PCCC 체크리스트)

5 장에서도 도입한 가설검정 4 단계는 6 장의 모든 검정에서 동일하게 적용된다. 본 장에서는 이 흐름을 PCCC(Prepare-Check-Calculate-Conclude) 로 부르며 매 예제에서 명시적으로 적용한다.



※ 5장에서 배운 절차를 6장 전반에 일관되게 적용한다.

Figure 3: 그림 6.0.2: 가설검정 4 단계 PCCC 체크리스트

PCCC 4 단계

1 단계 - 준비 (Prepare): 모수식별, 가설 H_0 와 H_a 설정, 유의수준 α 결정, 자료 요약 (n , p , 분할표).

2 단계 - 확인 (Check): 검정의 가정 (독립성, 표본크기조건) 을 검증한다. 가정이 위배되면 다른 방법 (시뮬레이션, 피셔정확검정 등) 을 고려한다.

3 단계 - 계산 (Calculate): 표준오차 SE 또는 기대빈도 E 를 계산하고, 검정통계량 (Z 또는 X^2) 를 구한 뒤 p -값을 산출한다.

4 단계 - 결론 (Conclude): p -값과 α 를 비교하여 H_0 기각 여부를 결정하고, 문제의 맥락에서 결론을 서술한다. “채택”이라는 표현은 절대 쓰지 않는다.

새로운 시각: “채택”과 “기각 못함”의 차이를 다시 강조 5 장 § 5.0 에서 강조한 내용을 6 장에서도 반복한다. 통계학에서는 다음 두 표현을 엄격히 구분한다.

- **올바른 표현:** “ H_0 를 기각할 충분한 증거가 없다” / “자료가 H_0 와 일관된다”
- **잘못된 표현:** “ H_0 를 채택한다” / “ H_0 가 참임이 증명되었다”

법정비유로 이해하면 쉽다. 무죄 추정 (H_0 : 무죄) 에서 시작한 재판이 “유죄 입증 실패”로 끝나도, 이는 **무죄임이 증명된 것이 아니라 유죄임을 입증하지 못했을 뿐**이다. 마찬가지로 p -값이 α 보다 크다고 해서 H_0 가 참이라고 결론지을 수 없다. 단지 자료가 H_0 를 강하게 부인하지 못한다는 것뿐이다.

6.0.3 5 장 핵심개념의 6 장 연결

5 장 § 5.0 에서 다룬 다음 개념들은 6 장 전반에 걸쳐 그대로 사용된다. 본절에서 핵심만 다시 정리한다.

(1) p-값 (p-value)

p-값의 정의 (§ 5.0.5 에서 다룬 내용 재확인)

p-값은 귀무가설 H_0 가 참이라는 가정하에서, 관측된 자료만큼 또는 그보다 더 극단적인 자료를 얻을 확률이다.

- $p\text{-값} < \alpha \rightarrow H_0$ 를 기각한다.
- $p\text{-값} \geq \alpha \rightarrow H_0$ 를 기각할 충분한 증거가 없다.

6 장의 모든 검정에서 결론의 핵심 지표는 p-값이다. 다만 검정 종류에 따라 p-값을 계산하는 분포가 정규분포 (Z-검정) 에서 카이제곱분포로 달라진다.

(2) 유의수준 α (significance level)

유의수준 α (§ 5.0.6 재확인)

α 는 **제 1 종 오류** (H_0 가 참인데 기각하는 오류) 를 범할 최대 허용 확률이다. 가장 흔한 선택은 $\alpha = 0.05$ 이지만, 상황에 따라 0.01(더 보수적) 또는 0.10(더 관대) 을 쓰기도 한다.

본장 § 6.1.5 에서 표본 크기 산정 시 α 를 어떻게 활용하는지 구체적으로 다룬다.

(3) 신뢰수준과 신뢰구간 (confidence level & interval)

신뢰구간의 해석 (§ 5.0.7 재확인)

“95% 신뢰구간”의 95% 는 **방법론**에 대한 신뢰도이지, 특정 구간이 모수를 포함할 확률이 아니다. 같은 절차로 100 개의 표본에서 신뢰구간을 만들면 그중 약 95 개가 모수를 포함한다는 의미이다.

신뢰구간과 가설검정은 다음과 같이 대응한다: - 95% CI 가 귀무가설을 포함하지 않음 $\Leftrightarrow$ 양측 $\alpha=0.05$ 검정에서 H_0 기각

6 장의 § 6.1.2(단일비율 CI), § 6.2.2(두 비율 차이의 CI) 에서 이 원리를 반복 적용한다.

(4) 단측 vs 양측검정

단측 vs 양측 (§ 5.0.4 재확인)

- **양측검정** ($H_0: \mu \neq \mu_0$): 차이의 방향을 미리 정하지 않는다. **사전 정보가 없을 때의 기본.**
- **단측검정** ($H_0: \mu > \mu_0$ 또는 $\mu < \mu_0$): 차이의 방향이 자료 수집 **이전**에 명확히 결정되어 있을 때만 사용한다.

주의: 자료를 본 뒤 “관측값이 더 크니 단측검정을 쓰자”는 식의 결정은 통계적 추론을 훼손한다. 단측검정은 반드시 자료 수집 전에 정해져야 한다.

(5) 제 1 종·제 2 종오류와검정력

오류와검정력 (§ 5.0.8, § 5.0.9 재확인)

- **제 1 종오류** (Type I error): H_0 가 참인데 기각. 발생확률 = α .
- **제 2 종오류** (Type II error): H_0 가 거짓인데 기각하지 못함. 발생확률 = β .
- **검정력** (power) = $1 - \beta$: H_0 가 거짓일 때 올바르게 기각할 확률.

표본크기를 늘리면 β 가 줄어 검정력이 높아진다.

본장 § 6.1.5 의 표본크기 산정논의는 본질적으로 “충분한 검정력을 확보하기 위해 n 을 얼마로 잡을 것인가”의 문제이다.

(6) 통계적유의성과실질적유의성

통계적 vs 실질적유의성 (§ 5.0.10 재확인)

“ $p < 0.05$ ” 자체는 효과가 **통계적으로 0 이아님**을 의미할 뿐, 그 효과의 **크기**가 실생활에서의 의미있는지는 별개의 문제이다. 표본크기가 매우 크면 실질적으로 무시할 만한 차이도 통계적으로 유의하게 잡힌다.

따라서 결론을 내릴 때는 항상 **점추정값**과 **신뢰구간**을 함께 보고하여 효과의 크기를 평가한다.

6.0.4 신뢰구간과 가설검정에서 SE 가 달라지는 이유

학생들이 자주 혼동하는 핵심 포인트를 별도로 정리한다. 6 장에서 **신뢰구간과 가설검정에서 표준오차 (SE) 가 다른 공식을 사용**한다는 것이다.

단일 비율: 신뢰구간 vs 가설검정의 표준오차

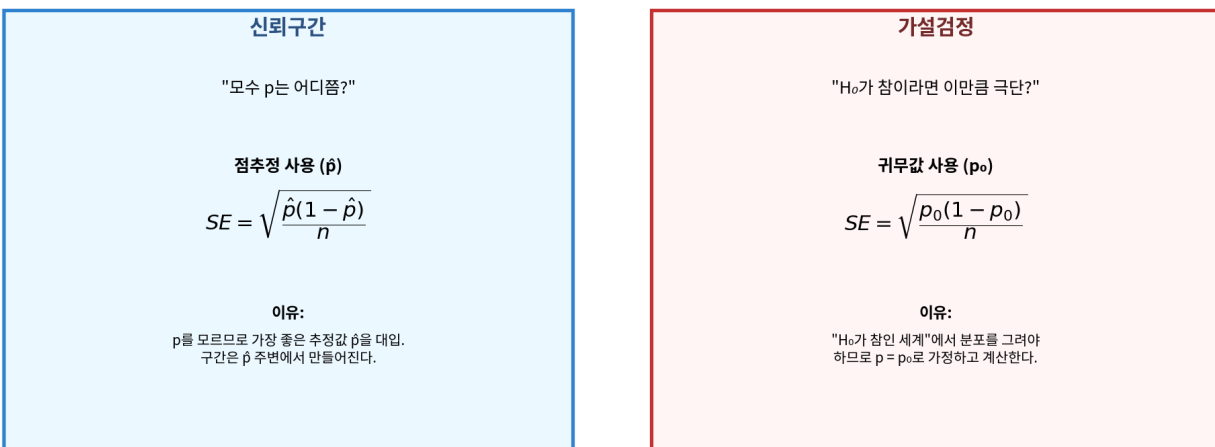


Figure 4: 그림 6.0.3: 신뢰구간 SE vs 가설검정 SE (단일비율)

단일비율의 경우

	신뢰구간	가설검정
사용하는비율	p (표본비율)	p (귀무값)
SE 공식	$\sqrt{\hat{p}(1-\hat{p})/n}$	$\sqrt{p_0(1-p_0)/n}$
성공-실패조건확인	$n\hat{p} \geq 10, n(1-\hat{p}) \geq 10$	$np_0 \geq 10, n(1-p_0) \geq 10$

왜다른가? - 신뢰구간은 “모수 p 가 어디쯤있을까”를 묻는다. p 를 모르므로 가장좋은추정값인 $\hat{p}$ 을대입한다. - 가설검정은 “ H_0 가 참 이라면이자료가얼마나극단적인가”를 묻는다. H_0 의세계에서분석하므로 $p = p_0$ 로가정하고계산한다.

두 비율의 차이: 신뢰구간 vs 가설검정의 표준오차




Figure 5: 그림 6.0.4: 두비율차이의 SE 비교 (비합동 vs 합동)

두비율의차이의경우

	신뢰구간 (비합동)	가설검정 (합동)
사용하는비율	p_1, p_2 각각	$\hat{p}_{\text{pool}} = (x_1 + x_2)/(n_1 + n_2)$
SE 공식	$\sqrt{\hat{p}_1(1-\hat{p}_1)/n_1 + \hat{p}_2(1-\hat{p}_2)/n_2}$	$\sqrt{\hat{p}_{\text{pool}}(1-\hat{p}_{\text{pool}})(1/n_1 + 1/n_2)}$

왜합동비율을쓰는가? 가설검정의귀무가설 $H_0: p_1 = p_2$ 에서는 **두모집단의참비율이동일하다고가정**한다. 이가정아래에서는두표본을합쳐서비율을추정하는것이통계적으로더효율적이다. 반면신뢰구간은두비율이같다고가정하지않으므로각그룹의 p 을따로사용한다.

6.0.5 카이제곱분포의직관 (§ 6.3 이전필독)

§ 6.3 에서처음으로등장하는 **카이제곱분포** (chi-square distribution, χ^2 distribution) 는학생들이자주어려워하는개념이다. § 6.3 에서본격적인계산을시작하기전에카이제곱분포자체의직관을충분히다진다.




Figure 6: 그림 6.0.5: 자유도에 따른 카이제곱 분포의 형태

(1) 카이제곱 분포는 어떻게 생겼는가 핵심성질: 1. 항상 0 이상의 값만 갖는다. 정규 분포처럼 음수 영역이 없다. 2. 오른쪽으로 치우친 (skewed) 비대칭 분포이다. 3. 자유도 (df) 가 커질수록 평균이 오른쪽으로 이동하고 분포가 평평해진다. 4. df 가 매우 크면 정규 분포에 가까워진다.

(2) 카이제곱 분포는 어디서 왔는가

카이제곱 분포의 기원

Z 가 표준정규 분포 $N(0,1)$ 을 따르면, Z^2 의 분포가 바로 **자유도 1 인 카이제곱 분포**이다. 즉, $X^2_{(1)} = Z^2$ 이다.

더 일반적으로, $Z_1, Z_2, \dots, Z_k$ 가 독립이고 모두 표준정규 분포를 따른다면:

$$Z_1^2 + Z_2^2 + \dots + Z_k^2 \sim X^2_{(k)}$$

즉, 카이제곱 분포는 **표준정규 변수들의 제곱의 합의 분포**이다.

이 사실로부터 다음이 즉시 따라온다: - **음수가 없는 이유**: 제곱은 항상 0 이상이므로. - **오른쪽 치우침의 이유**: 0 근처는 흔하지만 큰 값은 드물다.

- **자유도가 곧 “더해진 제곱항의 개수”**인 이유: 제곱들의 합이므로.

(3) 카이제곱 검정 통계량의 직관 § 6.3 과 § 6.4 에서 등장하는 카이제곱 검정 통계량은 다음과 같은 형태이다:

$$X^2 = \sum_{\text{모든 셀}} \frac{(O - E)^2}{E}$$

여기서 O 는 **관측빈도** (observed frequency), E 는 **기대빈도** (expected frequency, 즉 H_0 가 참일 때 예상되는 빈도) 이다.



카이제곱 분포의 기원: $Z^2 = \chi^2(df=1)$ Figure 7: 그림 6.0.6: 카이제곱분포의기원 ($Z^2 = \chi^2(df=1)$)카이제곱의 직관: 관측-기대 차이가 누적될수록 χ^2 이 커진다

Figure 8: 그림 6.0.7: 관측 vs 기대 - 카이제곱의 직관

해석: - 각셀에서 O 와 E 의차이를제곱하고, E 로나누어표준화한다. - 모든셀의기여도를더한다. - 자료가 H_0 와잘맞으면모든셀에서 $O \approx E$ 이므로 X^2 이작다. - 자료가 H_0 와잘맞지않으면 $(O-E)^2$ 항이커져서 X^2 이크다.




Figure 9: 그림 6.0.8: 카이제곱검정은오른쪽꼬리만사용

(4) 카이제곱검정은항상단측 (오른쪽) 검정

카이제곱검정의결정규칙

X^2 값이클수록자료가 H_0 와잘안맞는다는의미이므로, **항상분포의오른쪽꼬리면적만 p-값으로사용**한다. 이는 5 장의 Z-검정에서양측또는단측을선택하던것과다르다.

- 작은 $X^2 \rightarrow$ 자료가 H_0 와일관됨 $\rightarrow$ 큰 p-값 $\rightarrow H_0$ 기각못함
- 큰 $X^2 \rightarrow$ 자료가 H_0 와불일치 $\rightarrow$ 작은 p-값 $\rightarrow H_0$ 기각

새로운시각: 카이제곱검정에“양측/단측”구분이없는이유 5 장에서는“양측검정 vs 단측검정”을신중히구분해야했다. 하지만카이제곱검정에서는이구분이무의미하다. 왜일까?

이유는 X^2 의 **제곱구조**때문이다. $(O - E)^2$ 은차이의부호정보를모두잃어버린다. 즉, 관측이기대보다크든작든 X^2 에똑같이기여한다. 따라서 X^2 이크다는것은“어떤방향이든차이가있다”는의미이며, 이는본질적으로양측검정과같다. 단지검정통계량의분포자체가한쪽으로치우쳐있어형식상오른쪽꼬리만쓰는것일뿐, 의미는양측검정과동일하다.

이직관은 **2×2 분할표의경우카이제곱검정과 2-비율양측 Z-검정이정확히같은 p-값을준다**는사실로확인된다. 실제로 $X^2 = Z^2$ 관계가성립한다.

6.0.6 본장의학습순서

지금까지정리한개념들을바탕으로, 본장은다음순서로진행된다.

1. **§ 6.1 단일비율:** 5 장에서배운 1-비율추론을복습하고, 표본크기산정을추가로다룬다.
2. **§ 6.2 두비율의차이:** 정규분포기반추론을두그룹비교로확장한다. 합동/비합동 SE 의차이를명확히익힌다.
3. **§ 6.3 카이제곱적합도검정:** 한변수의빈도분포가정된분포 (예: 균등분포, 멘델비율) 와맞는지검정한다.
4. **§ 6.4 이원분할표독립성검정:** 두범주형변수의독립여부를검정한다.

각절에서 5 장의개념이어떻게적용되는지를명시적으로표시하므로, 5 장 § 5.0 과 6 장 § 6.0 을자유롭게오가며학습하기를권한다.

 6.1 단
 일비율
 에대한
 추론
 본절은
 5 장에
 서다룬
 단일비
 율추론
 을복습
 하면서,
 6 장의
 다른절
 들로가
 는디딤
 돌역할
 을한다.
 신뢰구
 간, 가
 설검정,
 표본크
 기산정
 세가지
 를차례
 로다룬
 다.

> 5 장**연결:**

본질의

모든내

용은

§ 5.1 ☒ § 5.3

과동일

한원리

이다.

본질에

서는자

료수집

단계의

표본크**기결정**

(§ 6.1.5)

을새로

추가한

다.

###

6.1.1

표본비

율이근

사적으

로정규

분포를

따르는

조건

표본관
측값이
독립이
고표본
크기가
충분히
크면,
표본비
율 p 는
은정규
분포를
사용하
여모델
링할수
있다.

> **p**

의표본

추출분

포 > >

참모집

단비율

p, 표

본크기

n 인단

순무작

위표본

에서표

본비율

p 은

다음조

건이충

족될때

근사적

으로정

규분포

를따른

다: >

> 1. **독**

립성:

표본관

측값이

독립이

다 (예:

단순무

작위표

본). >

2. **성**

공-실

배조건:

$np \geq$

10 이

고

$n(1 -$

$p) \geq$

10 이

다. >

> 이때

p 의

표분추

출분포

는평균

실제분
석에서
는 p 를
모르므
로, 신
뢰구간
이라면
 p 값을
가
설검정
이라면
귀무값
 p 값을
대입하
여 SE
를계산
한다
(§ 6.0.4
참고).

새로운
시각:
성
공-실
패조건
의직관

성
공-실
패조건
 $(np \geq 10$
그
리고
 $n(1 - p) \geq 10)$ 은
왜필요
한가?
이논이
항분포
(이산)
가정규
분포
(연속)
로충분
히근사
되는시
점을보
장하는
경험법
칙이다.

- n 이 작거나
 p 가 극단 (0 또는 1
에 가까움) 이면이항
분포가 비대칭
으로치우친다.
- 예:
 $n=20$,
 $p=0.05$
일때
 $np=1$
이므로
조건위배. 분포가
오른쪽으로
왜곡하
게치우
치고정
규근사
가실패
한다.

이“10
의규
칙”은
드무아
브르
(de
Moivre,
1733)
의정규
근사발
견이후
20 세
기통계
실무에
서경험
적으로
확립되
었다.

6.1.2 비율에대한신뢰구간

5 장연결: § 5.2 와동일한절차. PCCC 4 단계로정리하면다음과같다.

예제 6.1: 페이데이대출규제지지율 문제: 826 명의페이데이대출차입자단순무작위표본중 70% 가새로운규제를지지했다. 이표본비율을정규분포로모델링하는것이타당한가?

풀이 (PCCC 의 **C** - 확인단계):

- 독립성: 단순무작위표본이므로충족.
- 성공-실패조건 (신뢰구간이므로 p 사용):
 - $n\hat{p} = 826 \times 0.70 = 578 \geq 10 \checkmark$
 - $n(1 - \hat{p}) = 826 \times 0.30 = 248 \geq 10 \checkmark$

따라서정규분포로모델링할수있다.

```
import numpy as np
```

```
n = 826
```

```
p_hat = 0.70
```

```
# 성공-실패 조건 확인
```

```
print("=== 예제 6.1: 정규성 조건 확인 ===")
```

```
print(f"np = {n * p_hat:.0f} ≥ 10? {n * p_hat >= 10}")
```

```
print(f"n(1-p) = {n * (1 - p_hat):.0f} ≥ 10? {n * (1 - p_hat) >= 10}")
```

출력:

=== 예제 6.1: 정규성 조건 확인 ===

$np\hat{p} = 578 \geq 10$? True

$n(1-p\hat{p}) = 248 \geq 10$? True

Guided Practice 6.2: 표준오차계산 문제: 예제 6.1 의자료에서 $p\hat{p}$ 의표준오차를추정하라.

풀이 (PCCC 의 계산):

신뢰구간이므로 SE 공식에 $p\hat{p}$ 을대입한다 (§ 6.0.4 참고):

$$SE = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} = \sqrt{\frac{0.70 \times 0.30}{826}} = \sqrt{\frac{0.21}{826}} = 0.0160$$

```
import numpy as np
```

```
n = 826
```

```
p_hat = 0.70
```

```
se = np.sqrt(p_hat * (1 - p_hat) / n)
```

```
print(f"SE =  $\sqrt{0.70 \times 0.30 / 826}$  = {se:.4f}")
```

출력:

$SE = \sqrt{0.70 \times 0.30 / 826} = 0.0160$

예제 6.3: 95% 신뢰구간구성 문제: 페이데이대출규제지지를 p 에대한 95% 신뢰구간을구성하라.

풀이:

PCCC 의 4 단계를모두따른다.

- **준비:** 모수 p , 점추정값 $\hat{p} = 0.70$, $n = 826$, 신뢰수준 95%.
- **확인:** 예제 6.1 에서조건충족확인.
- **계산:** $SE = 0.0160$ (GP 6.2). 95% CI 에대한 $z^* = 1.96$.

$$\hat{p} \pm z^* \cdot SE = 0.70 \pm 1.96 \times 0.0160 = (0.669, 0.731)$$

- **결론:** 페이데이대출차입자중규제를지지하는모집단비율 p 가 **66.9%**~**73.1%** 사이에있다고 95% 신뢰한다.

```
import numpy as np
```

```
from scipy import stats
```

```
n = 826
```

```
p_hat = 0.70
```

```
conf = 0.95
```

```

se = np.sqrt(p_hat * (1 - p_hat) / n)
z_star = stats.norm.ppf((1 + conf) / 2)
me = z_star * se
lower, upper = p_hat - me, p_hat + me

print(f"=== 95% 신뢰구간 ===")
print(f"p̂      = {p_hat}")
print(f"SE      = {se:.4f}")
print(f"z*      = {z_star:.3f}")
print(f"오차한계 ME = {me:.4f}")
print(f"95% CI = ({lower:.3f}, {upper:.3f})")

```

출력:

```

=== 95% 신뢰구간 ===
p̂      = 0.7
SE      = 0.0160
z*      = 1.960
오차한계 ME = 0.0313
95% CI = (0.669, 0.731)

```

6.1.3 비율에대한가설검정

5 장면결: § 5.3 의검정절차를다시적용한다. 신뢰구간과달리 SE 계산에 **귀무값 p_0** 를사용한다 (§ 6.0.4).

Guided Practice 6.4: 가설설정 문제: 차입자들이신용조회·부채상환평가규제에다수가찬성또는반대하는지평가하기위한가설을 설정하라.

풀이:

다수찬성/반대여부를묻고있으므로 50% 를귀무값으로잡고 **양측검정**으로시작한다 (§ 6.0.3 의단측 vs 양측원칙):

- $H_0: p = 0.50$ (차입자의정확히절반이지지—즉, 다수도소수도아님)
- $H_a: p \neq 0.50$ (다수또는소수가지지)

여기서 p 는신용조회·부채상환평가규제를지지하는모든페이데이대출차입자의비율이다.

Guided Practice 6.5: 가설검정의조건확인 문제: 826 명중 51% 가규제를지지했다. $p̂ = 0.51$ 을가설검정에사용하기위해 정규분포로모델링할수있는가?

풀이:

가설검정이므로성공-실패조건은 **귀무값 $p_0 = 0.5$** 로확인한다 (§ 6.0.4):

- $np_0 = 826 \times 0.50 = 413 \geq 10 \checkmark$
- $n(1 - p_0) = 826 \times 0.50 = 413 \geq 10 \checkmark$

두 조건이 모두 충족되므로 p 값을 정규분포로 모델링할 수 있다.

예제 6.6: 가설검정완료 문제: 위가설과자료로페이데이대출차입자다수가규제를지지한다는설득력있는증거가있는지평가하라 ($\alpha = 0.05$).

풀이 (PCCC 완전적용):

- **준비:** $H_0: p = 0.5$, $H_a: p \neq 0.5$, $\alpha = 0.05$, $p_{\text{hat}} = 0.51$, $n = 826$.
- **확인:** GP 6.5 에서확인.
- **계산:**
 - SE (귀무값사용): $\sqrt{0.5 \times 0.5 / 826} = 0.0174$
 - 검정통계량: $Z = (0.51 - 0.50) / 0.0174 = 0.57$
 - 양측 p-값: $2 \times P(Z > 0.57) = 0.5687$ (약 0.56)
- **결론:** p-값 (0.56) > $\alpha(0.05)$ 이므로 H_0 를 **기각하지못한다**. 페이데이대출차입자의다수가신용조회·부채상환평가규제에찬성또는반대한다는설득력있는증거가자료에서발견되지않는다.

```
import numpy as np
```

```
from scipy import stats
```

```
n = 826
```

```
p_hat = 0.51
```

```
p_0 = 0.50
```

```
alpha = 0.05
```

```
se = np.sqrt(p_0 * (1 - p_0) / n)
```

```
z = (p_hat - p_0) / se
```

```
p_value = 2 * (1 - stats.norm.cdf(abs(z)))
```

```
print(f"=== 예제 6.6: 단일 비율 양측 검정 ===")
```

```
print(f"SE (귀무값 사용) = {se:.4f}")
```

```
print(f"Z = {z:.2f}")
```

```
print(f"양측 p-값 = {p_value:.4f}")
```

```
print(f"결론: p-값 ({p_value:.4f}) {'<' if p_value < alpha else '≥'} α({alpha}) → H0 를 {'기각' if p_value < alpha else '기각하지 못함'}
```

출력:

```
=== 예제 6.6: 단일 비율 양측 검정 ===
```

```
SE (귀무값 사용) = 0.0174
```

```
Z = 0.57
```

```
양측 p-값 = 0.5687
```

```
결론: p-값(0.5687) ≥ α(0.05) → H0를 기각하지 못함
```




Figure 10: 그림 6.1: 예제 6.6 양측검정의정규분포시각화

새로운시각: “기각못함”이“지지없음”과같지않은이유 위결론에서우리는“다수찬성/반대의증거가없다”고만말했지, “다수가 50% 이다”또는“차이가없다”고말하지않았다. 이는 § 6.0.2 에서강조한원칙의적용이다.

만약표본크기 n 이 10,000 명이고 $\hat{p} = 0.51$ 이었다면, 같은 1% 차이라도 SE 가작아져서 Z 가커지고 p -값이작아질것이다. 실제로 계산하면 $Z = 2.0$, p -값 ≈ 0.046 이되어 $\alpha = 0.05$ 기준으로는기각된다. **같은자료의비율이지만표본크기에따라결론이달라지는것**이다.

이는 § 6.0.3 (6) 의“통계적유의성 vs 실질적유의성”과직결된다. 본예제에서차이 1% 가실질적으로의미가있는지는별도의정책적·실무적판단이다.

6.1.4 조건이충족되지않을때

성공-실패조건이위배되거나독립성에의심이있을때는정규근사를쓸수없다. 대안은다음과같다.

가설검정의경우: 귀무값 p_0 를사용한 **시뮬레이션**으로귀무분포를직접만든다 (2.3 절의말라리아사례연구와 유사).

신뢰구간의경우: **클로퍼-피어슨구간** (Clopper-Pearson interval) 을사용한다. 본서범위를벗어나지만, `scipy` 등에서쉽게계산할 수있다.

클로퍼-피어슨 구간 예시 (성공-실패 조건 위배 시)

```
from scipy import stats
```

```
x = 2 # 성공 횟수
```

```
n = 20 # 시도 횟수
```

```
conf = 0.95
```

```
lower = stats.beta.ppf((1 - conf)/2, x, n - x + 1) if x > 0 else 0
upper = stats.beta.ppf(1 - (1 - conf)/2, x + 1, n - x) if x < n else 1

print(f"x={x}, n={n}, p̂={x/n:.3f}")
print(f"클로퍼-피어슨 95% CI: ({lower:.3f}, {upper:.3f})")
```

독립성위배는더미묘하다. 표본추출설계의결함 (예: 동일가구에서여러명표본, 군집표본등) 일수있으므로 **자료가어떻게수집되었는지**를반드시검토해야한다.

6.1.5 비율을추정할때표본크기결정

자료수집단계에서, 신뢰구간의 **오차한계** (margin of error, ME) 가충분히작도록표본크기 n 을미리정해야한다. 이절차는본질적으로 § 5.0.9 에서다룬검정력논의와연결된다 (더큰 $n \rightarrow$ 더작은 SE $\rightarrow$ 더좁은 CI $\rightarrow$ 더높은검정력).

표본크기공식 (비율추정)

신뢰수준 $(1-\alpha)$ 에서오차한계를 ME 이하로만들려면:

$$n \geq \frac{p(1-p) \cdot (z^*)^2}{ME^2}$$

- p 에대한사전정보가있으면그값을대입.
- p 에대한사전정보가없으면 **$p = 0.5$** 를대입 (가장보수적, 즉가장큰 n).

p 에대한사전정보가없을때 $p = 0.5$ 를쓰는이유는, $p(1-p)$ 가 $p = 0.5$ 에서최댓값 0.25 를가시기때문이다.




Figure 11: 그림 6.2: $p(1-p)$ 함수— $p=0.5$ 에서 최대 0.25

예제 6.7: 표본크기산정 문제: 대학신문이등록금인상지지를설문을 95% 신뢰수준, $ME < 0.04$ 로 실시하려한다. 표본크기는얼마여야하는가?

풀이:

p 에대한사전정보가없으므로 $p = 0.5$ 를대입:

$$1.96 \cdot \sqrt{\frac{0.5 \times 0.5}{n}} < 0.04$$

n 에대해풀면:

$$n > \frac{0.5 \times 0.5 \times 1.96^2}{0.04^2} = \frac{0.25 \times 3.8416}{0.0016} = 600.25$$

따라서 **최소 601 명**을표본으로모집해야한다.

```
import numpy as np
from scipy import stats

me_target = 0.04
conf = 0.95
p_assume = 0.5 # 보수적 가정

z_star = stats.norm.ppf((1 + conf) / 2)
n = p_assume * (1 - p_assume) * (z_star / me_target) ** 2

print(f"=== 예제 6.7: 표본크기 산정 ===")
print(f"z* = {z_star:.3f}")
print(f"계산된 n = {n:.2f}")
print(f"필요한 최소 n = {int(np.ceil(n))}")
```

출력:

```
=== 예제 6.7: 표본크기 산정 ===
z* = 1.960
계산된 n = 600.25
필요한 최소 n = 601
```

Guided Practice 6.8: 사전정보가있을때 문제: 시범연구에서 $p \approx 0.35$ 라는정보가있다면 $ME < 0.04$ 를더작은 n 으로달성할수있는가?

풀이:

$p(1-p) = 0.35 \times 0.65 = 0.2275 < 0.25$ 이므로가능하다.

$$n > \frac{0.35 \times 0.65 \times 1.96^2}{0.04^2} = \frac{0.2275 \times 3.8416}{0.0016} \approx 546.2$$

따라서 **최소 547 명**으로충분하다.

```
p = 0.35
n = p * (1 - p) * (1.96 / 0.04) ** 2
print(f"p = {p}일 때 필요한 n = {int(np.ceil(n))}")
```

출력:

p = 0.35일 때 필요한 n = 547




Figure 12: 그림 6.7: 표본크기와오차한계의관계

새로운시각: 표본크기결정의비대칭성 표본크기를 4 배로늘리면 SE 는 $\sqrt{4} = 2$ 배작아지고 ME 도절반으로줄어든다. 즉 **정밀도는 $\sqrt{n}$ 비율로증가**한다.

이는의외로큰함의를갖는다. 예를들어 ME 를 10% 에서 1% 로줄이려면표본크기를 100 배늘려야한다. 따라서매우정밀한추정을요구하는연구는비용이급격히증가한다. 이때문에연구설계단계에서“어느정도의 ME 가 실질적으로충분한가”를미리정하는것이중요하다.

6.2 두비율의차이

본절에서는두모집단의비율 p_1 과 p_2 를비교한다. 점추정값은자연스럽게 $\hat{p}_1 - \hat{p}_2$ 이고, 추론의큰흐름은단일비율과같다. 다만표준오차공식과정규성조건확인방법이약간달라진다.

5 장연결: 본절은 5 장에서다루지않은새로운응용이지만, PCCC 4 단계는그대로적용된다.

6.2.1 두비율차이의표본추출분포

$\hat{p}_1 - \hat{p}_2$ 가정규분포를따르는조건

1. **확장독립성**: 자료가두그룹 **내에서**그리고두그룹 **사이에서**독립이다 (예: 두독립표본, 무작위실험).
2. **각그룹에서성공-실패조건**: 두그룹모두에서성공과실패가각각 10 이상예상된다.

이조건이충족되면:

$$SE_{\hat{p}_1 - \hat{p}_2} = \sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}}$$

새로운시각: 차이의분산은왜분산의합인가 직관과어긋날수있지만, 독립확률변수 X, Y 에대해:

$$\text{Var}(X - Y) = \text{Var}(X) + \text{Var}(Y)$$

부호가더하기에서빼기로바뀌어도분산은더해진다. 이유는분산이분포의 **퍼짐정도**를재량수이기때문이다. X 에서빼든더하든 Y 가가져오는 불확실성은그대로더해진다.

따라서 $\hat{p}_1 - \hat{p}_2$ 의표준오차는두표본비율의분산을더하고제곱근을취한것이다.

6.2.2 두비율차이의신뢰구간 (비합동 SE)

5 장연결: 신뢰구간공식의일반형태 (점추정 $\pm z^* \times SE$) 는동일하다. 신뢰구간에서는두그룹의표본비율 $\hat{p}_1, \hat{p}_2$ 를각 SE 공식에대입한다 (§ 6.0.4).

예제 6.11: CPR 연구의정규성조건확인 **문제**: 심정지후 CPR 을받은환자들이혈전용해제 (처치군) 또는대조군에무작위배정되었다. 결과는 24 시간생존여부였다.

그룹	생존	사망	합계
대조군	11	39	50
처치군	14	26	40

두표본비율의차이를정규분포로모델링할수있는가?

풀이:

- **독립성**: 무작위실험이므로충족.
- **성공-실패조건**: 각그룹에서성공과실패가모두 10 이상.
 - 대조군: $11 \geq 10 \checkmark, 39 \geq 10 \checkmark$
 - 처치군: $14 \geq 10 \checkmark, 26 \geq 10 \checkmark$

두조건이모두충족되므로정규분포로모델링할수있다.

예제 6.12: CPR 연구의 90% 신뢰구간 문제: 처치군과대조군의생존율차이에대한 90% 신뢰구간을구성하라.

풀이 (PCCC):

- 준비: $\hat{p}_T = 14/40 = 0.35$, $\hat{p}_C = 11/50 = 0.22$, 신뢰수준 90%.
- 확인: 예제 6.11 에서확인.
- 계산 (비합동 SE):
 - 점추정: $\hat{p}_T - \hat{p}_C = 0.35 - 0.22 = 0.13$
 - $SE = \sqrt{\frac{0.35 \times 0.65}{40} + \frac{0.22 \times 0.78}{50}} = \sqrt{0.005688 + 0.003432} = 0.0955$
 - 90% CI 에서 $z^* = 1.645$
 - 90% CI: $0.13 \pm 1.645 \times 0.0955 = (-0.027, 0.287)$
- 결론: 처치군과대조군의 24 시간생존율차이가 **-0.027** $\boxtimes$ **0.287** 사이에있다고 90% 신뢰한다. **이구간이 0 을포함하므로**, 혈전용해제가생존율에영향을미치지않을가능성도자료와일관된다.

```
import numpy as np
from scipy import stats
```

```
n_t, x_t = 40, 14
n_c, x_c = 50, 11
```

```
p_t = x_t / n_t
p_c = x_c / n_c
diff = p_t - p_c
```

```
# 신뢰구간이므로 비합동 SE
```

```
se = np.sqrt(p_t*(1 - p_t)/n_t + p_c*(1 - p_c)/n_c)
z_star = stats.norm.ppf(0.95) # 90% CI
me = z_star * se
lo, hi = diff - me, diff + me
```

```
print(f"=== 예제 6.12: CPR 연구 90% CI ===")
print(f"점추정 p_T - p_C = {diff:.3f}")
print(f"SE (비합동)      = {se:.4f}")
print(f"z*                  = {z_star:.3f}")
print(f"90% CI              = ({lo:.3f}, {hi:.3f})")
print(f"CI 가 0 을 포함? {'예 → 차이 결론 불가' if lo <= 0 <= hi else '아니오 → 차이 있음'})")
```

출력:

```
=== 예제 6.12: CPR 연구 90% CI ===
점추정 p_T - p_C = 0.130
SE (비합동)      = 0.0955
z*               = 1.645
90% CI           = (-0.027, 0.287)
```

CI가 0을 포함? 예 → 차이 결론 불가




Figure 13: 그림 6.3: CPR 연구 90% 신뢰구간

6.2.3 두비율차이의가설검정 (합동 SE)

5 장연결: 가설검정절차는 § 5.3 과동일하지만, SE 계산에 **합동비율**을사용한다 (§ 6.0.4). 이유는귀무가설 $H_0: p_1 = p_2$ 하에서는두모집단비율이같다고가정하므로, 두표본을합쳐서비율을추정하는것이통계적으로더효율적이기때문이다.

합동비율 (pooled proportion)

$$\hat{p}_{\text{pool}} = \frac{x_1 + x_2}{n_1 + n_2}$$

가설검정의표준오차:

$$SE_{\text{pool}} = \sqrt{\hat{p}_{\text{pool}}(1 - \hat{p}_{\text{pool}}) \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}$$

예제 6.14: 직장승진율검정 문제: 한직장의무작위표본에서남성 21 명중 14 명이승진했고, 여성 24 명중 12 명이승진했다. $\alpha = 0.05$ 에서승진율차이가있는지검정하라.

풀이 (PCCC):

- 준비:
 - $H_0: p_m = p_f, H_A: p_m \neq p_f$ (양측, 사전방향정보없음).
 - $\alpha = 0.05$.
 - $\hat{p}_m = 14/21 = 0.667, \hat{p}_f = 12/24 = 0.500$.

- **확인** (가설검정이므로 합동비율로 성공-실패점검):

- $\hat{p}_{\text{pool}} = (14 + 12)/(21 + 24) = 26/45 = 0.578$
- 남성: $21 \times 0.578 = 12.1$ (성공), $21 \times 0.422 = 8.9$ (실패) — 실패측이 약간 부족하지만 큰 위반은 아님.
- 여성: $24 \times 0.578 = 13.9$, $24 \times 0.422 = 10.1$ ✓
- 조건이 거의 충족된다고 보고 진행.

- **계산:**

- 점추정: $\hat{p}_m - \hat{p}_f = 0.667 - 0.500 = 0.167$
- 합동 SE: $\sqrt{0.578 \times 0.422 \times (1/21 + 1/24)} = 0.148$
- $Z = 0.167/0.148 = 1.13$
- 양측 p-값: $2 \times P(Z > 1.13) = 0.258$

- **결론:** p-값 (0.258) > $\alpha(0.05)$ 이므로 H_0 를 **기각하지 못한다**. 남성과 여성의 승진율이 다르다는 설득력 있는 증거가 이 자료에서 발견되지 않는다.

```
import numpy as np
from scipy import stats
```

```
x_m, n_m = 14, 21
x_f, n_f = 12, 24
```

```
p_m = x_m / n_m
p_f = x_f / n_f
diff = p_m - p_f
```

```
# 가설검정이므로 합동 SE
p_pool = (x_m + x_f) / (n_m + n_f)
se_pool = np.sqrt(p_pool * (1 - p_pool) * (1/n_m + 1/n_f))
z = diff / se_pool
p_value = 2 * (1 - stats.norm.cdf(abs(z)))
```

```
print(f"=== 예제 6.14: 두 비율 양측 검정 ===")
print(f"p_m = {p_m:.3f}, p_f = {p_f:.3f}")
print(f"점추정 차이 = {diff:.3f}")
print(f"합동 비율 = {p_pool:.3f}")
print(f"합동 SE = {se_pool:.4f}")
print(f"Z = {z:.2f}")
print(f"양측 p-값 = {p_value:.3f}")
print(f"결론: p-값 ({p_value:.3f}) {'<' if p_value < 0.05 else '≥'} α(0.05) → H0 를 {'기각' if p_value < 0.05 else '수용'}
```

출력:

```
=== 예제 6.14: 두 비율 양측 검정 ===
p_m = 0.667, p_f = 0.500
점추정 차이 = 0.167
합동 비율 = 0.578
```

합동 SE = 0.148

$Z = 1.13$

양측 p-값 = 0.258

결론: $p\text{-값}(0.258) \geq \alpha(0.05) \rightarrow H_0$ 를 기각하지 못함

새로운시각: 합동 SE vs 비합동 SE 를잘못쓰면? 가설검정에서비합동 SE 를쓰거나, 신뢰구간에서합동 SE 를쓰면어떻게될까? 답은 “대부분의경우큰차이는없지만, 이론적으로부정확”이다.

- 가설검정에서비합동 SE 를쓰면, H_0 의가정 ($p_1=p_2$) 을무시하고 SE 를추정하는셈이된다. p-값이약간부정확해진다.
- 신뢰구간에서합동 SE 를쓰면, 두비율이같다고가정하므로구간자체의해석이모순된다.

표본크기가충분히크면합동/비합동의결과차이는매우작지만, **방법론적정확성**을위해각상황에맞는 SE 를쓰는것이원칙이다.

6.3 카이제곱적합도검정

5 장연결: 새로운검정도구이지만 PCCC 4 단계는동일하다. 카이제곱분포의직관은 § 6.0.5 에서충분히다루었다.

본절에서는 **한변수의빈도분포가가정된분포와일치하는지**검정하는카이제곱적합도검정 (chi-square goodness-of-fit test) 을다룬다.

6.3.1 적합도검정의동기: 배심원인종구성

미국어느카운티의인종구성과배심원후보풀의인종구성을비교한다. 가설은“배심원풀이인종균형분포에서무작위로뽑혔는가”이다.

이를일반화하면: **관측된빈도들이어떤이론적분포와잘맞는가?** 이것이적합도검정의핵심질문이다.

6.3.2 카이제곱검정통계량

카이제곱적합도검정통계량

k 개범주에서관측빈도 $O_1, O_2, \dots, O_k$ 와 H_0 에서기대빈도 $E_1, E_2, \dots, E_k$ 를비교한다:

$$X^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}$$

H_0 가참이면 X^2 은근사적으로 **자유도 $df = k - 1$** 인카이제곱분포를따른다.

§ 6.0.5 에서다룬직관그대로, 관측-기대차이가큰셀이 많을수록 X^2 이커지고, H_0 가잘안맞는다는신호가된다.

6.3.3 적합도검정의조건

카이제곱검정의조건

- 독립성:** 관측들이독립이다 (예: 단순무작위표본).
- 표본크기조건:** 모든셀의기대빈도 $E_i \geq 5$.

6.3.4 사례연구: S&P500 일별등락의독립성

문제: S&P500 지수의일별상승다음에다시상승할때까지걸리는거래일수를기록했다. 거래일등락이독립이라면이대기시간은 **기하분포** (geometric distribution) 를따라야한다.

대기일	관측 O	기대 E (기하분포)
1 일	717	743
2 일	369	338
3 일	155	154
4 일	69	70
5 일	28	32
6 일	14	15
7 일 +	10	12

Guided Practice 6.34: 검정통계량계산

$$X^2 = \frac{(717 - 743)^2}{743} + \frac{(369 - 338)^2}{338} + \frac{(155 - 154)^2}{154} + \frac{(69 - 70)^2}{70} + \frac{(28 - 32)^2}{32} + \frac{(14 - 15)^2}{15} + \frac{(10 - 12)^2}{12}$$

$$= 0.91 + 2.84 + 0.01 + 0.01 + 0.50 + 0.07 + 0.33 = 4.61$$

```
import numpy as np
from scipy import stats

observed = np.array([717, 369, 155, 69, 28, 14, 10])
expected = np.array([743, 338, 154, 70, 32, 15, 12])

contributions = (observed - expected) ** 2 / expected
chi2 = contributions.sum()
df = len(observed) - 1
p_value = 1 - stats.chi2.cdf(chi2, df)

print(f"=== S&P500 적합도 검정 ===")
print(f" 각 셀의 (O-E)²/E:")
for i, (o, e, c) in enumerate(zip(observed, expected, contributions), 1):
    print(f" 대기 {i}일: ({o}-{e})²/{e} = {c:.2f}")
print(f"\nX² = {chi2:.2f}")
print(f"df = {df}")
print(f"p-값 = {p_value:.4f}")
print(f"\n결론: p-값 ({p_value:.3f}) ≥ α(0.05) → 기하분포 (거래일 독립) 와 일관됨")
```

출력:

```
=== S&P500 적합도 검정 ===
```


각 셀의 $(O-E)^2/E$:

$$\text{대기 1일: } (717-743)^2/743 = 0.91$$

$$\text{대기 2일: } (369-338)^2/338 = 2.84$$

$$\text{대기 3일: } (155-154)^2/154 = 0.01$$

$$\text{대기 4일: } (69-70)^2/70 = 0.01$$

$$\text{대기 5일: } (28-32)^2/32 = 0.50$$

$$\text{대기 6일: } (14-15)^2/15 = 0.07$$

$$\text{대기 7일: } (10-12)^2/12 = 0.33$$

$$\chi^2 = 4.67$$

$$df = 6$$

$$p\text{-값} = 0.5867$$

결론: $p\text{-값}(0.587) \geq \alpha(0.05) \rightarrow$ 기하분포(거래일 독립)와 일관됨




Figure 14: 그림 6.4: S&P500 적합도검정시각화

예제 6.37: 결론의해석 (다시강조) p -값이크다고해서“거래일이확실히독립”이라고결론짓는것은아니다. 단지자료가독립성가정과 일관된다는의미일뿐이다 (§ 6.0.2 재참고). 이는효율적시장가설과부합하지만, “증명”이아닌“비반증”이다.

6.4 이원분할표에서의독립성검정

5 장연결: 새로운분야이지만 PCCC 4 단계와카이제곱분포의직관 (§ 6.0.5) 이그대로적용된다.

본절은 **두범주형변수가독립인지**를검정한다. 자료구조는 $R \text{ 행} \times C \text{ 열}$ 의이원분할표이다.

6.4.1 기대빈도계산

이원분할표에서 두 변수가 독립이라면, 각 셀의 기대빈도는 행합계와 열합계의 곱을 전체합계로 나눈 값이다.

이원분할표의 기대빈도

i 행 j 열 셀의 기대빈도:

$$E_{ij} = \frac{(\text{i 행합계}) \times (\text{j 열합계})}{\text{전체합계}}$$

6.4.2 사례연구: iPod 결함공개실험

중고 iPod 을 판매하는 사람들을 세 그룹에 무작위로 배정하고, 각 그룹이 받는 질문 형식만 달리 하여 결함 공개율을 비교한다.

질문 형식	일반	긍정가정	부정가정	합계
문제공개	2	23	36	61
문제숨김	71	50	37	158
합계	73	73	73	219

전체공개율: $61/219 = 0.279$

귀무가설 H_0 : 질문 형식과 공개여부 독립.

기대빈도 (행합계 $\times$ 열합계 / 219): - 공개행: $61 \times 73/219 = 20.33$ (각열) - 숨김행: $158 \times 73/219 = 52.67$ (각열)

6.4.3 검정통계량과 자유도

이원분할표 카이제곱검정

$$X^2 = \sum_{\text{모든셀}} \frac{(O - E)^2}{E}$$

자유도: $df = (R - 1)(C - 1)$

여기서 R, C 는 분할표의 행/열수.

예제 6.40: iPod 실험검정 풀이 (PCCC):

- **준비:** H_0 : 질문 형식과 공개여부 독립. H_a : 독립이 아니다. $\alpha = 0.05$.
- **확인:** 모든 기대빈도 ≥ 5 ✓, 무작위 실험으로 독립성 ✓.
- **계산:**
 - 각 셀 $(O-E)^2/E$:
 - * $(2-20.33)^2/20.33 = 16.53$
 - * $(23-20.33)^2/20.33 = 0.35$

$$\begin{aligned}
 & * (36-20.33)^2/20.33 = 12.06 \\
 & * (71-52.67)^2/52.67 = 6.38 \\
 & * (50-52.67)^2/52.67 = 0.14 \\
 & * (37-52.67)^2/52.67 = 4.66 \\
 & - X^2 = 40.13 \\
 & - df = (2-1)(3-1) = 2 \\
 & - p\text{-값} \approx 2 \times 10^{-9} \text{ (매우작음)}
 \end{aligned}$$

- 결론: H_0 를 강하게 기각. 질문형식이 결합공개여부에 강한영향을 미친다는 설득력 있는 증거가 있다.

```
import numpy as np
from scipy import stats
```

```
# 관측 분할표
```

```
observed = np.array([[2, 23, 36],      # 공개
                     [71, 50, 37]])    # 숨김
```

```
chi2, p, dof, expected = stats.chi2_contingency(observed)
```

```
print(f"=== 예제 6.40: iPod 실험 카이제곱 검정 ===")
print(f"기대빈도:\n{expected}\n")
print(f"X^2 = {chi2:.2f}")
print(f"df = {dof}")
print(f"p-값 = {p:.2e}")
print(f"\n결론: p-값이 매우 작음 → H0 강하게 기각")
print(f"    질문 형식이 결합 공개율에 큰 영향")
```

```
# 각 그룹 공개율
```

```
print(f"\n그룹별 공개율:")
for name, col in zip(['일반', '긍정가정', '부정가정'], range(3)):
    rate = observed[0, col] / observed[:, col].sum() * 100
    print(f" {name}: {rate:.1f}%")
```

출력:

```
=== 예제 6.40: iPod 실험 카이제곱 검정 ===
기대빈도:
[[20.33333333 20.33333333 20.33333333]
 [52.66666667 52.66666667 52.66666667]]
```

```
X^2 = 40.13
df = 2
p-값 = 1.93e-09
```

결론: p-값이 매우 작음 → H_0 강하게 기각

질문 형식이 결함 공개율에 큰 영향

그룹별 공개율:

일반: 2.7%

긍정가정: 31.5%

부정가정: 49.3%

iPod 결함 공개 실험: 질문 형식이 공개율에 매우 큰 영향




Figure 15: 그림 6.5: iPod 실험결과

새로운시각: iPod 실험의응용 이 실험은 단순한 통계예제가 아닙니다. 질문 형식만으로 공개율이 **2.7%에서 49.3%로 18배 증가**한 것은 다음 분야에 직접적 시사점을 준다:

- **회계감사·법률면담:** 부정가정형 질문이 사실 발견에 더 효과적.
- **의료면담:** 환자에게 “약 복용에 어려움이 있으셨죠?” vs “약 복용에 문제는 없으셨나요?”의 차이.
- **설문조사 설계:** 응답편향 (response bias)을 줄이기 위한 질문 작성 원칙.

통계적 결론의 실질적 의미가 매우 큰 사례이다 (§ 6.0.3 (6) 의 실질적 유의성).

6.5 장 요약

6.5.1 6 장 핵심개념정리

절	시나리오	검정통계량	분포	비고
6.1	단일비율	$Z = (\hat{p} - p_0)/SE$	$N(0,1)$	SE에 p_0 사용
6.2	두 비율 차이 (가설검정)	$Z = (\hat{p}_1 - \hat{p}_2)/SE_{\text{pool}}$	$N(0,1)$	합동비율 사용
6.2	두 비율 차이 (CI)	—	$N(0,1)$	비합동 SE 사용

절	시나리오	검정통계량	분포	비고
6.3	적합도검정	$X^2 = \frac{\sum (O - E)^2}{E}$	χ^2_{k-1}	모든 $E_i \geq 5$
6.4	독립성검정	$X^2 = \frac{\sum (O - E)^2}{E}$	$\chi^2_{(R-1)(C-1)}$	모든 $E_{ij} \geq 5$

6.5.2 5 장과 6 장의연결

5 장에서배운개념	6 장에서의적용
가설검정 4 단계 (PCCC)	모든절에서동일하게사용
p-값과 α 비교	검정통계량의분포만달라짐
단측 vs 양측	Z-검정에적용. 카이제곱은항상 (사실상) 양측
제 1 종·제 2 종오류	표본크기산정의근거
신뢰구간과가설검정의대응	단일/두비율모두에서성립
통계적 vs 실질적유의성	iPod 실험등에서효과크기평가

6.5.3 다음장예고

7 장에서는수치형자료에대한추론을다룬다. 6 장에서정규분포에서카이제곱분포로도구를확장한것처럼, 7 장에서는표본평균을위한 **t-분포**를확장한다. 가설검정의큰흐름은또다시동일하다.